PROJET INTÉGRATEUR · SCIENCE DES DONNÉES

Cancer de la prostate

Revue de littérature : repères cliniques, biologiques et data-science

Ce document rassemble les notions cliniques et biologiques nécessaires pour comprendre le jeu de données `prostate.csv`, situer le problème dans son contexte épidémiologique — notamment africain — et formuler une problématique métier défendable devant un jury.

> 28 références · 3 figures · arrêt de la recherche : novembre 2026
>
> Usage : chapitre « problématique métier » du rapport et socle notionnel du projet
>
> Revue narrative — non systématique

Sommaire

Avant-propos : à quoi sert ce document . . . 3

1. La maladie en dix lignes . . . 3

2. Épidémiologie : le poids mondial et le signal africain . . . 4

3. Anatomie et physiopathologie . . . 5

4. Facteurs de risque et prévention . . . 6

5. Le PSA : la molécule, le test, et ses limites . . . 6

6. Dépistage : une controverse fondatrice . . . 8

7. Le diagnostic : de la suspicion à la preuve histologique . . . 9

8. La gradation histologique : Gleason et groupes ISUP . . . 10

9. Stadification et groupes de risque . . . 11

10. Les traitements, en bref . . . 12

11. Facteurs pronostiques et modèles prédictifs . . . 13

12. Le cancer de la prostate en Afrique . . . 13

13. Science des données et cancer de la prostate : état des lieux . . . 14

14. Votre jeu de données dans ce paysage . . . 15

15. Ce qu'il faut retenir pour la suite du projet . . . 17

16. Limites de cette revue . . . 17

17. Glossaire . . . 17

18. Références . . . 18

Avant-propos : à quoi sert ce document

Cette revue de littérature a un objectif précis : vous donner les notions cliniques et biologiques nécessaires pour comprendre ce que contient réellement le fichier `prostate.csv`, et pour formuler une problématique métier défendable devant un jury. Elle est écrite pour un profane motivé : chaque notion est définie avant d'être utilisée, et chaque chiffre est sourcé.

Trois précautions de méthode. Premièrement, il s'agit d'une **revue narrative**, non d'une revue systématique : il n'y a ni protocole PRISMA, ni critères d'inclusion explicites, ni extraction standardisée. Le risque de biais de sélection est donc réel, même si la priorité a été donnée aux sources primaires et aux synthèses de référence. Deuxièmement, la littérature médicale sur ce sujet est pléthorique (plusieurs dizaines de milliers de références) : le document sélectionne ce qui est utile au projet, pas ce qui est exhaustif. Troisièmement, les recommandations évoluent vite ; les chiffres épidémiologiques cités sont ceux de GLOBOCAN 2022, publication de référence au moment de la rédaction (novembre 2026).

Un mot sur l'usage que vous pouvez en faire : les sections 1 à 11 constituent le socle « métier » du rapport, la section 12 le cadrage africain attendu par l'énoncé du TP, et les sections 13 et 14 la jonction avec la science des données. Les encadrés « À retenir » sont rédigés pour être réutilisés presque tels quels.

1. La maladie en dix lignes

Le cancer de la prostate est, dans plus de 95 % des cas, un **adénocarcinome** : une tumeur qui naît de l'épithélium glandulaire de la prostate, c'est-à-dire des cellules qui produisent le liquide séminal. Il se développe préférentiellement dans la **zone périphérique**, qui représente plus de 70 % du tissu glandulaire et où surviennent la quasi-totalité des carcinomes ; l'hypertrophie bénigne, elle, siège plutôt dans la zone de transition [3]. Cette localisation anatomique a une conséquence clinique directe : les tumeurs postérieures sont palpables au toucher rectal, les tumeurs antérieures ne le sont pas — d'où le rôle central de l'imagerie.

Trois idées structurent tout le reste du document.

1. C'est le **cancer le plus fréquent chez l'homme** dans le monde, avec environ 1,47 million de nouveaux cas par an [1,2].
2. C'est un cancer **extraordinairement hétérogène** : certains ne progresseront jamais et ne nécessiteront aucun traitement, d'autres métastasent et tuent en quelques années. Distinguer les deux est le problème clinique central, et c'est la source du surdiagnostic et du surtraitement.
3. Le marqueur sanguin de référence, le **PSA**, est spécifique de l'organe mais pas du cancer : il s'élève aussi dans l'hypertrophie bénigne et l'inflammation. Toute la stratégie diagnostique consiste à gérer cette imprécision.

> **À retenir** — Le cancer de la prostate est fréquent, lent dans sa forme majoritaire, et biologiquement silencieux. Le problème n'est pas de le détecter à tout prix, mais de distinguer à temps les formes qui tueront.

2. Épidémiologie : le poids mondial et le signal africain

2.1 Les chiffres de référence

Les estimations GLOBOCAN 2022 de l'International Agency for Research on Cancer situent le cancer de la prostate au **deuxième rang des cancers masculins** (1 467 854 nouveaux cas, derrière les 1,57 million de cas de cancer du poumon) et au **quatrième rang tous cancers confondus** [1,2]. La mortalité est de **397 430 décès**, soit un taux standardisé monde de 7,3 pour 100 000 hommes, contre 29,4 pour l'incidence.

Cette apparente disproportion entre incidence et mortalité traduit la longue histoire naturelle de la maladie : on meurt rarement d'un cancer de la prostate, on meurt *avec*. Mais ce constat global masque des écarts considérables entre régions, et c'est là que se trouve l'information la plus utile pour un projet ancré dans le contexte africain.

Région	Nouveaux cas (2022)	Part mondiale	Décès (2022)	Part mondiale	Ratio décès / cas
Europe	473 011	32,2 %	115 182	29,0 %	24,4 %
Asie	386 424	26,3 %	120 485	30,3 %	31,2 %
Amérique du Nord	255 782	17,4 %	39 605	10,0 %	15,5 %
Amérique latine et Caraïbes	225 985	15,4 %	61 056	15,4 %	27,0 %
Afrique	**103 050**	**7,0 %**	**55 744**	**14,0 %**	**54,1 %**
Océanie	23 602	1,6 %	5 358	1,3 %	22,7 %

Source : fiche GLOBOCAN 2022 « Prostate », IARC [2]. Ratio calculé par nos soins.

2.2 Le ratio mortalité/incidence, indicateur le plus parlant

En Afrique, un homme diagnostiqué d'un cancer de la prostate a statistiquement **plus d'une chance sur deux** de mourir de sa maladie (54,1 % de décès pour 100 cas). En Amérique du Nord, ce rapport tombe à 15,5 %, et à 24,4 % en Europe. Autrement dit, à incidence comparable, le pronostic diffère d'un facteur trois à quatre selon le continent.

Ce n'est pas un artefact statistique lié à la qualité des registres, même si celle-ci joue. Une étude de survie portant sur 1 406 patients issus de 12 registres de population d'Afrique subsaharienne (10 pays, 2005-2015) retrouve **45,2 % de diagnostics au stade IV et 31,2 % au stade III** ; seuls 23,6 % des patients dont le stade est connu sont diagnostiqués aux stades I-II, et la survie relative à 5 ans n'est que de **60,0 %** [19]. À titre de comparaison, aux États-Unis, 69,5 % des cancers sont diagnostiqués à un stade localisé, et la survie relative à 5 ans d'une forme localisée atteint 100 %, contre environ 38 % en cas de métastases [26,27].

Le message est donc simple : **le problème africain n'est pas principalement l'incidence, c'est le stade au diagnostic**. Et le stade au diagnostic dépend de l'accès au dépistage, à l'imagerie et à la biopsie — c'est-à-dire de ressources.

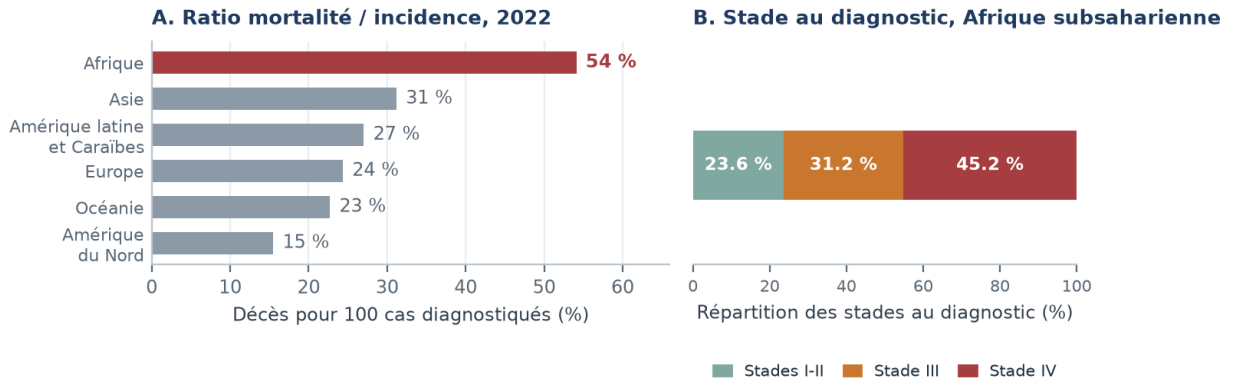


Figure 1 — (A) Décès pour 100 cas diagnostiqués, par région, en 2022. (B) Répartition des stades au diagnostic en Afrique subsaharienne. Sources : GLOBOCAN 2022 [2] ; Seraphin et al. [19].

> **À retenir** — 7 % des cas mondiaux mais 14 % des décès : l'Afrique porte une part de mortalité double de sa part d'incidence. Le retard diagnostique, et non la biologie, explique l'essentiel de cet écart.

2.3 Perspectives démographiques

Le vieillissement de la population et la croissance démographique suffisent, à taux constants, à doubler le nombre annuel de cas en Afrique en une vingtaine d'années [19]. Aucune amélioration du dépistage n'est donc nécessaire pour que la charge double : c'est un effet mécanique de la structure d'âge. Ce point est important pour votre argumentaire métier : le besoin d'outils de priorisation peu coûteux va croître, indépendamment de toute innovation technologique.

3. Anatomie et physiopathologie

3.1 Une glande, trois zones

La description zonale de McNeal (1981) reste la référence [3]. La prostate est subdivisée en une **zone périphérique** (environ 70 % du tissu glandulaire, siège de la majorité des cancers et des prostatites chroniques), une **zone de transition** (10 %, siège de l'hypertrophie bénigne) et une **zone centrale** (20 %). S'y ajoutent le stroma fibromusculaire antérieur, région mal vascularisée où les tumeurs peuvent se développer à l'abri du toucher rectal.

Cette géographie explique deux faits cliniques. D'une part, l'hypertrophie bénigne et le cancer naissent dans des zones différentes, mais leurs symptômes se recouvrent (troubles urinaires, envies fréquentes). D'autre part, une tumeur antérieure peut atteindre un volume important sans être palpable : c'est précisément ce que l'IRM multiparamétrique est venue corriger.

3.2 De la cellule normale au carcinome

Les cellules épithéliales prostatiques dépendent des **androgènes** (testostérone, convertie en dihydrotestostérone) et de leur récepteur nucléaire, le récepteur aux androgènes (AR). Cette dépendance est la base de l'hormonothérapie : priver la tumeur d'androgènes la fait régresser. Elle est aussi la base de l'échec thérapeutique : sous pression de traitement, des clones résistants émergent et le cancer devient **résistant à la castration** (CRPC), phase où la maladie redevient mortelle.

La séquence histologique classique passe par une **néoplasie intraépithéliale de haut grade** (PIN), lésion précancéreuse, puis un carcinome localisé, une extension extraprostatique, un envahissement ganglionnaire et enfin des métastases, majoritairement **osseuses** et de type ostéocondensant (le tissu osseux se densifie autour des cellules tumorales). Les métastases osseuses sont responsables de douleurs, de fractures pathologiques et de compression médullaire : ce sont elles qui font la morbidité de la maladie avancée.

3.3 Pourquoi le mot « cancer » est trompeur

Un adénocarcinome de score de Gleason 6 (voir section 8) ne présente, dans l'état actuel des connaissances, qu'un potentiel métastatique extrêmement faible. Certains auteurs proposent de le requalifier pour éviter le mot « cancer » et son cortège d'anxiété et de traitements inutiles. Cette particularité explique pourquoi la prostate est le terrain privilégié du débat sur le **surdiagnostic** : détecter un cancer qui n'aurait jamais fait de mal n'est pas un bénéfice, c'est un préjudice (traitement, complications, coût, anxiété).

4. Facteurs de risque et prévention

Les facteurs de risque établis sont peu nombreux mais puissants.

- **L'âge** : l'incidence augmente fortement après 50 ans, et la prévalence autopsique de foyers tumoraux dépasse 50 % chez les hommes de plus de 80 ans. C'est le premier facteur de risque, et il n'est pas modifiable.
- **L'ascendance africaine** : les hommes d'ascendance africaine ont une incidence plus élevée, un diagnostic plus précoce en moyenne (dès 40-45 ans selon le NCCN [21]) et une mortalité nettement supérieure — de l'ordre de deux à cinq fois selon les sources américaines [21,23]. Les facteurs génétiques (région 8q24, scores de risque polygéniques) et les facteurs sociaux (accès aux soins, confiance dans le système de santé) se conjuguent.
- **Les antécédents familiaux** et les prédispositions héréditaires : les variants pathogènes de **BRCA2** confèrent un risque élevé et une maladie plus agressive ; HOXB13 est également impliqué.
- **Les facteurs métaboliques** : obésité, syndrome métabolique et tabac sont associés à des formes plus agressives, sans que la causalité soit démontrée.

La prévention primaire reste décevante. Aucune intervention nutritionnelle n'a démontré d'effet convaincant en essai randomisé (le lycopène et les oméga-3 ont fait l'objet d'essais négatifs ou contradictoires). Les inhibiteurs de la 5-alpha-réductase (finastéride, dutastéride) réduisent l'incidence des formes de bas grade, mais au prix d'un biais de détection et sans bénéfice démontré sur la mortalité : ils ne sont pas recommandés comme chimioprévention.

5. Le PSA : la molécule, le test, et ses limites

5.1 Biologie

Le PSA (*prostate-specific antigen*) est une glycoprotéine sécrétée par l'épithélium prostatique, de la famille des kallikréines (kallikréine-3, hK3). Sa fonction naturelle est de liquéfier le coagulum séminal. Il circule dans le sang sous forme libre ou liée à des protéines, et sa demi-vie sérique est de deux à trois jours [12].

Deux propriétés définissent son usage clinique. Il est **spécifique de l'organe** : seule la prostate en produit (avec de faibles quantités dans les glandes péri-urétrales). Il n'est **pas spécifique du cancer** : toute augmentation de la perméabilité de l'épithélium — hypertrophie bénigne, prostatite, infarctus prostatique,

geste instrumental — fait monter le taux sérique. Le PSA est donc un marqueur de *volume et d'inflammation prostatiques*, dont le cancer n'est qu'une des causes d'élévation.

Les variations non tumorales sont nombreuses et doivent être connues : hypertrophie bénigne (contribution majeure, de l'ordre de 0,12 ng/mL par gramme de tissu bénin), prostatite aiguë (élévations spectaculaires), éjaculation dans les 48 heures, cyclisme prolongé, sondage ou biopsie récente. Le toucher rectal modifie peu le taux.

5.2 Le seuil de 4 ng/mL et son talon d'Achille

Le seuil historique de 4 ng/mL a été choisi pour sa sensibilité : il détecte environ **91 % des cancers** [12]. Mais sa **spécificité est faible** : dans une méta-analyse portant sur des seuils inférieurs à 4 ng/mL, la sensibilité regroupée atteignait 0,92 tandis que la spécificité variait de 0,02 à 0,63 selon les études et les populations [11]. Autrement dit, la grande majorité des hommes dont le PSA dépasse 4 ng/mL n'ont pas de cancer, et une proportion substantielle de ceux qui en ont un ont un PSA normal.

La valeur prédictive positive dépend en outre de la prévalence : le même seuil, appliqué à une population de 50 ans non suspecte ou à une consultation d'urologie, ne signifie pas la même chose. C'est un point de méthode important pour la suite : **un modèle prédictif hérite de la prévalence de la population sur laquelle il est entraîné**, et ne se transpose pas sans recalibration.

5.3 Les raffinements du dosage

Plusieurs paramètres ont été développés pour améliorer la spécificité, avec des succès inégaux.

- **La cinétique** : vélocité (variation annuelle) et temps de doublement. Utiles surtout en suivi.
- **La densité** : PSA rapporté au volume prostatique mesuré à l'échographie ou à l'IRM ; une densité élevée oriente vers le cancer plutôt que vers l'hypertrophie.
- **Le ratio PSA libre / PSA total** : un ratio bas (< 10-15 %) est associé au cancer, surtout dans la zone 4-10 ng/mL.
- **Les indices composites** : *Prostate Health Index* (PHI), 4Kscore, qui combinent plusieurs isoformes et facteurs cliniques.
- **Les scores de risque polygéniques**, encore en cours de validation et très dépendants de l'ascendance.

Aucun de ces outils n'a remplacé le dosage simple, mais tous illustrent la même logique : **le PSA seul est un signal bruité, et l'information utile vient de sa combinaison avec d'autres variables**. C'est exactement la logique d'un modèle multivarié.

5.4 Conséquence directe pour votre modélisation

Le PSA sérique est distribué de façon approximativement **log-normale** : c'est pourquoi il est modélisé sur l'échelle logarithmique dans la littérature biomédicale, et c'est pourquoi votre variable cible s'appelle `lpsa` et non `psa`. Cette transformation n'est pas cosmétique : elle linéarise la relation entre volume tumoral et PSA, stabilise la variance et rend les résidus interprétables.

La relation entre volume tumoral et PSA est forte mais imparfaite. Stamey et ses collègues estimaient qu'un centimètre cube de cancer élève le PSA sérique d'environ 3,5 ng/mL, soit au moins dix fois ce que produit le tissu bénin à volume égal [4]. C'est le fondement biologique de la corrélation que vous observerez dans vos données (r = 0,73 entre `lcavol` et `lpsa`). Mais cette relation est bruyante, parce que le volume tumoral n'est qu'un des déterminants : la différenciation cellulaire, l'inflammation associée, l'hypertrophie coexistante et la variabilité individuelle comptent aussi.

> **À retenir** — Le PSA est un marqueur d'organe, pas de cancer. Sa force est la sensibilité, sa faiblesse la spécificité. Un modèle qui prédit le PSA à partir de variables cliniques capture une relation biologique réelle, mais nécessairement entachée d'un bruit important.

6. Dépistage : une controverse fondatrice

6.1 Ce que disent les essais

Deux essais randomisés majeurs ont structuré le débat, avec des résultats apparemment contradictoires.

L'essai européen **ERSPC** (182 000 hommes, 7 pays) a montré une réduction de la mortalité par cancer de la prostate d'environ **20 %** avec un dépistage par PSA tous les 2 à 4 ans, réduction qui s'est confirmée avec l'allongement du suivi [9]. L'essai américain **PLCO** (76 000 hommes) n'a trouvé **aucun bénéfice** en mortalité [10] — mais son bras contrôle a été largement « contaminé » par un dépistage opportuniste, ce qui rend la comparaison peu informative. La lecture dominante aujourd'hui est que le dépistage par PSA réduit modérément la mortalité spécifique, au prix d'un surdiagnostic important.

6.2 Le prix du dépistage

Le surdiagnostic est la conséquence mécanique du dépistage d'une maladie à histoire naturelle longue et à prévalence élevée chez les sujets âgés : on détecte des cancers qui ne seraient jamais devenus cliniquement visibles. Les estimations varient, mais une part substantielle des cancers dépistés (souvent citée entre 20 et 50 % selon les modèles et les seuils d'âge) n'aurait jamais été symptomatique. À cela s'ajoutent les faux positifs, les biopsies inutiles et leurs complications infectieuses, et le surtraitement.

6.3 Les recommandations actuelles

L'USPSTF américaine recommande, depuis 2018, une **décision partagée** pour les hommes de 55 à 69 ans (grade C : bénéfice modeste, choix individuel) et une **non-recommandation** au-delà de 70 ans (grade D) [8]. Les recommandations européennes (EAU) s'orientent vers un dépistage **à risque adapté** : dosage dès 50 ans (45 ans si antécédents familiaux ou ascendance africaine), espacement des dosages, IRM avant biopsie et arrêt du dépistage chez les hommes à faible espérance de vie.

En Afrique subsaharienne, il n'existe **pas de programme de dépistage organisé** dans la plupart des pays. Le dépistage est opportuniste, souvent déclenché par des campagnes ponctuelles, et le diagnostic intervient fréquemment à l'occasion de symptômes — donc à un stade avancé [19,20]. Les recommandations du NCCN préconisent de commencer la discussion dès **40 à 45 ans** chez les hommes d'ascendance africaine [21].

> **À retenir** — Le dépistage par PSA sauve des vies, modérément, et coûte cher en surdiagnostics. En Afrique, le problème n'est pas le surdiagnostic mais l'absence de dépistage : on diagnostique tard, donc on meurt plus.

7. Le diagnostic : de la suspicion à la preuve histologique

7.1 La séquence diagnostique

Le parcours typique comporte quatre étapes.

1. **Suspicion clinique ou biologique** : PSA élevé, toucher rectal anormal (nodule, induration, asymétrie), ou symptômes urinaires.
2. **IRM multiparamétrique** (T2, diffusion, perfusion), systématique avant toute biopsie dans les recommandations récentes. Elle localise les lésions suspectes et évite des biopsies inutiles.
3. **Biopsie prostatique**, ciblée sur les lésions IRM et/ou systématique (schéma en 12 carottes), par voie transrectale ou transpérinéale. La voie transpérinéale réduit le risque infectieux.
4. **Examen anatomopathologique** : type histologique, score de Gleason, nombre de carottes envahies, pourcentage d'envahissement.

7.2 L'IRM et le score PI-RADS

Le **PI-RADS** (*Prostate Imaging Reporting and Data System*), dans sa version 2.1 (2019), standardise l'interprétation de l'IRM multiparamétrique en cinq catégories [14].

Score PI-RADS	Probabilité de cancer cliniquement significatif	Conduite habituelle
1	Très faible	Pas de biopsie
2	Faible	Pas de biopsie
3	Intermédiaire	Biopsie discutée (contexte, densité de PSA, cinétique)
4	Élevée	Biopsie ciblée
5	Très élevée	Biopsie ciblée, parfois stadification immédiate

Le concept de **cancer cliniquement significatif** (csPCa) est central : il désigne une tumeur qui justifie une intervention, définie par un grade ISUP ≥ 2 (Gleason ≥ 7), et/ou un volume supérieur à 0,5 cm^3, et/ou une extension extraprostatique [14]. C'est cette définition, et non la simple présence de cancer, qui guide les décisions.

7.3 La stadification

Une fois le diagnostic posé, la stadification repose sur le toucher rectal, le PSA, l'imagerie (IRM, scanner, scintigraphie osseuse) et, de plus en plus, la **tomographie par émission de positons au PSMA** (PSMA-PET), qui détecte les localisations ganglionnaires et osseuses avec une sensibilité supérieure à l'imagerie conventionnelle. Son usage se généralise dans les situations de récidive biochimique et de maladie à haut risque.

8. La gradation histologique : Gleason et groupes ISUP

8.1 Le système de Gleason

Le score de Gleason décrit l'**architecture** des glandes tumorales, cotée de 1 à 5 (1 = glandes bien formées, 5 = cellules isolées, sans structure glandulaire). Le score total additionne les deux architectures les plus représentées : par exemple 3+4 = 7. Les grades 1 et 2 ne sont plus utilisés en pratique, ce qui fait que les scores observés vont de 6 (3+3) à 10 (5+5).

8.2 La réforme ISUP 2014

Le score de Gleason souffrait d'un défaut pédagogique majeur : le score minimal possible étant 6, un patient à 3+3 = 6 croyait avoir un cancer « moyen » alors qu'il s'agit de la forme la plus indolente. La conférence de consensus ISUP de 2014, publiée en 2016, a introduit cinq **groupes de grade** (Grade Groups, GG) numérotés de 1 à 5 [5].

Groupe ISUP	Score de Gleason	Description	Pronostic
GG 1	3+3 = 6	Glandes bien formées uniquement	Très favorable, potentiel métastatique très faible
GG 2	3+4 = 7	Prédominance de grade 3, composante 4 minoritaire	Favorable à intermédiaire
GG 3	4+3 = 7	Prédominance de grade 4	Intermédiaire, pronostic significativement moins bon que GG 2
GG 4	8 (4+4, 3+5, 5+3)	Architecture largement dédifférenciée	Défavorable
GG 5	9-10	Absence de structure glandulaire	Très défavorable

La distinction entre 3+4 et 4+3 est l'apport principal de cette réforme : elle sépare deux populations qui partageaient le même chiffre « 7 » alors que leurs risques de récidive diffèrent nettement [5]. C'est un excellent exemple de la façon dont une variable bien construite change la valeur prédictive d'un modèle.

8.3 Le lien avec votre jeu de données

Deux variables de `prostate.csv` renvoient directement à cette section.

- `gleason` : le score total, observé ici de 6 à 9. C'est une variable **ordinale**, pas continue : l'écart entre 6 et 7 n'a pas la même signification clinique qu'entre 8 et 9, et le codage numérique linéaire est une approximation.
- `pgg45` : le pourcentage de grade 4 ou 5 dans la tumeur. Cette variable est souvent négligée par les analystes, alors qu'elle mesure l'**hétérogénéité** tumorale, c'est-à-dire la présence d'un clone dédifférencié. Elle est fortement corrélée au score de Gleason (r = 0,75 dans vos données) mais porte une information différente : deux tumeurs de score 7 peuvent avoir 5 % ou 60 % de grade 4, et leur pronostic n'est pas le même.

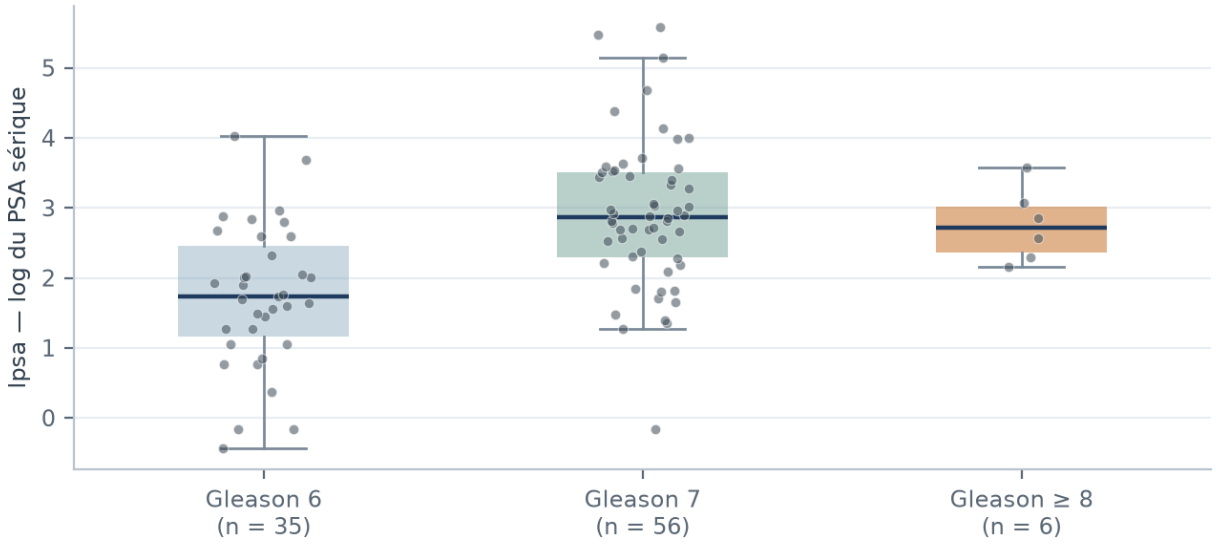


Figure 2 — Distribution du log du PSA selon le groupe de Gleason dans `prostate.csv`*. Les effectifs sont très déséquilibrés : 35 patients Gleason 6, 56 Gleason 7, 6 Gleason ≥ 8.*

9. Stadification et groupes de risque

9.1 Le TNM

La 8e édition de la classification AJCC (2017) distingue le stade clinique (cTNM) et le stade pathologique (pTNM), et intègre pour la première fois le PSA et le groupe de grade dans les groupes pronostiques.

- **T1** : tumeur non palpable, découverte par le PSA ou la chirurgie.
- **T2** : tumeur limitée à la prostate (T2a : la moitié d'un lobe ou moins ; T2b : plus de la moitié d'un lobe, sans atteinte de l'autre ; T2c : les deux lobes).
- **T3** : extension au-delà de la capsule. **T3a** : extension extraprostatique ; **T3b** : envahissement des vésicules séminales.
- **T4** : envahissement des organes adjacents (vessie, rectum, parois).
- **N** : ganglions régionaux. **M** : métastases à distance.

Les deux variables `svi` (envahissement des vésicules séminales, donc pT3b) et `lcp` (pénétration capsulaire, donc pT3a) de votre fichier correspondent exactement à ces deux situations, qui sont des facteurs pronostiques majeurs de récidive.

9.2 La classification de D'Amico

Publiée en 1998 et toujours utilisée comme langage commun, elle répartit les cancers localisés en trois groupes de risque de récidive biochimique après traitement local [7].

Groupe	PSA	Gleason	Stade clinique
Faible risque	< 10 ng/mL	≤ 6	T1c-T2a
Risque intermédiaire	10-20 ng/mL	7	T2b
Haut risque	> 20 ng/mL	8-10	≥ T2c

La règle est disjonctive : **un seul critère suffit** à faire basculer le patient dans la catégorie supérieure. Le NCCN affine ensuite en six catégories (très faible, faible, intermédiaire favorable, intermédiaire défavorable, haut risque, très haut risque), avec des implications thérapeutiques directes.

> **À retenir** — Le risque n'est pas une variable, c'est une construction : PSA + grade + stade, combinés selon des règles explicites. C'est déjà, au fond, un modèle prédictif — un modèle additif, transparent, validé sur des dizaines de milliers de patients.

10. Les traitements, en bref

10.1 Les options

- **Surveillance active** : pour les cancers de faible risque et certains risques intermédiaires favorables. Elle consiste à surveiller (PSA, IRM, biopsies de confirmation) et à ne traiter qu'en cas de progression. C'est le traitement de référence de plus en plus de patients, précisément pour éviter le surtraitement.
- **Prostatectomie radicale** : ablation de la glande, par voie ouverte, cœlioscopique ou robot-assistée, avec préservation des bandelettes nerveuses lorsque cela est oncologiquement possible. Complications : incontinence urinaire (souvent transitoire), dysfonction érectile.
- **Radiothérapie externe** : conformationnelle, avec modulation d'intensité, éventuellement associée à une hormonothérapie de 4 à 36 mois selon le risque.
- **Curiethérapie** : implantation de grains radioactifs, pour les formes localisées de faible risque.
- **Hormonothérapie** (ADT) : agonistes ou antagonistes de la LHRH, qui suppriment la production de testostérone. Utilisée en association à la radiothérapie, ou en traitement de la maladie avancée.
- **Traitements de la maladie résistante à la castration** : abiratérone, enzalutamide, apalutamide, docétaxel, et **radiothérapie interne vectorisée au lutétium-177-PSMA**. L'essai VISION a montré, dans cette situation, une survie globale médiane de 15,3 mois contre 11,3 mois (rapport de risque 0,62) [18].

10.2 Ce que ProtecT a changé

L'essai ProtecT a randomisé plus de 1 600 hommes atteints d'un cancer localisé entre surveillance active, prostatectomie et radiothérapie. À 10 ans, la **mortalité spécifique était faible et identique dans les trois bras** [16]. À 15 ans, les hommes du bras surveillance présentaient davantage de métastases et de décès par cancer de la prostate, mais la mortalité globale restait comparable [17]. Ce résultat a deux lectures : il valide la surveillance active comme option sûre pour beaucoup de patients, et il rappelle que le bénéfice d'un traitement local se mesure à vingt ans, pas à cinq.

10.3 Le coût, angle mort des systèmes contraints

Un traitement curatif complet (chirurgie ou radiothérapie) représente plusieurs milliers de dollars, auxquels s'ajoutent l'imagerie, l'anatomopathologie et le suivi. Dans les systèmes de santé à financement public limité, la question n'est pas seulement « quel est le meilleur traitement ? » mais « pour qui le traitement apportera-t-il le plus grand bénéfice ? ». C'est précisément le type de question qu'un modèle prédictif peut aider à trancher — à condition d'être calibré sur la population concernée.

11. Facteurs pronostiques et modèles prédictifs

11.1 Les facteurs validés

Les facteurs pronostiques les mieux établis après traitement local sont le **PSA pré-thérapeutique**, le **groupe de grade ISUP**, le **stade T**, l'**envahissement des vésicules séminales**, le **statut des marges chirurgicales** et l'**envahissement ganglionnaire**. À ceux-ci s'ajoutent des facteurs liés au patient (âge, comorbidités) et au système de soins (délai de prise en charge, accès aux traitements).

La **récidive biochimique** est définie, après prostatectomie, par un PSA qui remonte au-dessus de 0,2 ng/mL à deux reprises ; après radiothérapie, par un nadir + 2 ng/mL (critère de Phoenix). C'est le critère de jugement le plus utilisé dans les essais, car il précède les métastases de plusieurs années.

11.2 Les nomogrammes

Le nomogramme de Kattan, publié en 1999 puis mis à jour, prédit la probabilité de rester sans récidive biochimique après prostatectomie à partir de variables cliniques et pathologiques [15]. Sa précision interne est de l'ordre de 77 à 81 % à 5, 10, 15 et 20 ans. Des validations externes ont toutefois montré une performance variable selon les centres et les époques, ce qui illustre une leçon générale : **un modèle performant dans sa cohorte de développement ne l'est pas nécessairement ailleurs**.

11.3 Les biomarqueurs récents

Trois familles se sont ajoutées : les tests génomiques tissulaires (Decipher, Oncotype DX GPS, Prolaris), qui affinent la prédiction d'agressivité à partir de l'ARN tumoral ; l'imagerie quantitative (PI-RADS, radiomique) ; et les marqueurs circulants (cellules tumorales circulantes, ADN tumoral circulant). Aucun n'a remplacé la combinaison PSA + grade + stade, mais plusieurs modifient déjà les décisions dans les zones d'incertitude.

12. Le cancer de la prostate en Afrique

12.1 Une charge sous-estimée

Les 103 050 cas et 55 744 décès africains de 2022 [2] sont probablement des **sous-estimations** : la couverture des registres est partielle, une partie des décès survient à domicile sans certification, et le recours au système de soins est limité par le coût. Le fardeau réel est donc au moins égal, probablement supérieur.

Le retentissement économique est double : coût direct des soins (chirurgie, radiothérapie, médicaments), et coût indirect lié à la mortalité d'hommes en âge d'activité. La prostatectomie et la radiothérapie restent inaccessibles à une large partie de la population, et les traitements de la maladie avancée (abiratérone, Lu-PSMA) sont très rarement disponibles.

12.2 Les causes du retard diagnostique

La littérature qualitative identifie des barrières convergentes [19,20] : méconnaissance de la maladie et des symptômes, représentations sociales (le cancer perçu comme une fatalité, la peur de la féminisation liée aux troubles sexuels), priorité donnée aux urgences économiques, recours aux tradipraticiens, coût du bilan, disponibilité irrégulière du dosage de PSA, délais d'accès à l'IRM et à l'anatomopathologie, et absence de filière structurée.

Il faut y ajouter une barrière propre au dépistage : le toucher rectal, perçu comme intrusif, et la crainte de la biopsie. Les campagnes de sensibilisation qui ne traitent que l'information biomédicale, sans traiter ces

représentations, obtiennent des résultats limités.

12.3 La dimension génétique

Les hommes d'ascendance africaine présentent une incidence plus élevée et des formes plus agressives. Les explications sont multiples : variants de susceptibilité plus fréquents dans la région 8q24 [22], architecture génomique différente des tumeurs, scores de risque polygéniques développés majoritairement sur des cohortes d'ascendance européenne et donc mal calibrés [23], et facteurs sociaux. La sous-représentation des populations africaines dans les biobanques est un problème majeur : **un modèle entraîné sur une cohorte européenne n'est pas transposable**, et l'affirmer sans le vérifier est une faute méthodologique.

12.4 Ce que cela implique pour un modèle « frugal »

Le contexte africain impose des contraintes de conception : variables peu coûteuses (âge, PSA, toucher rectal, éventuellement échographie), pas de dépendance à l'IRM ou à un scanner, fonctionnement hors ligne, interprétabilité, et validation locale. C'est exactement le cahier des charges d'un modèle tabulaire simple — et c'est ce qui rend votre projet pédagogiquement pertinent, à condition de ne pas surestimer sa portée clinique.

> **À retenir** — En Afrique subsaharienne, le cancer de la prostate tue parce qu'il est diagnostiqué tard, dans des systèmes où l'IRM et la biopsie sont des goulots d'étranglement. Un modèle qui exploite des données déjà disponibles pour hiérarchiser les patients a une utilité potentielle réelle, mais il doit être validé localement avant tout usage.

13. Science des données et cancer de la prostate : état des lieux

13.1 Trois familles de travaux

La littérature en apprentissage automatique appliquée au cancer de la prostate se répartit en trois familles.

1. **Les modèles tabulaires** (données cliniques et biologiques), qui cherchent à prédire la présence d'un cancer, son grade ou sa récidive. Ce sont les plus proches de votre projet.
2. **L'imagerie**, dominée par l'apprentissage profond sur IRM multiparamétrique : détection et segmentation des lésions, prédiction du caractère cliniquement significatif, prédiction du grade à partir de l'image. Les revues systématiques rapportent des performances élevées, souvent supérieures à celles des radiologues pris isolément, mais avec une hétérogénéité méthodologique considérable [25].
3. **Les approches multimodales et omiques**, qui combinent imagerie, clinique et données moléculaires.

Les méta-analyses récentes confirment que les modèles d'apprentissage automatique atteignent des performances diagnostiques élevées (souvent > 75-80 % d'aires sous la courbe), mais soulignent trois limites récurrentes : un **risque de biais élevé** dans la majorité des études, une **absence fréquente de validation externe**, et une **faible reproductibilité** des résultats publiés [24].

13.2 Les jeux de données publics

Jeu de données	Taille	Contenu	Usage typique
Prostate (Stamey) / ISLR	97 patients	8 variables clinico-pathologiques + PSA	Pédagogie de la régression, sélection de variables
PLCO	~77 000 hommes	Essai de dépistage, données longitudinales	Prédiction du risque, épidémiologie
SEER	Registre populationnel	Incidence, stade, survie, traitements	Épidémiologie, modèles de survie
TCGA-PRAD	499 tumeurs	Génomique, transcriptomique, clinique	Biomarqueurs moléculaires
ProtecT	~1 600 patients	Essai randomisé, suivi long	Comparaison de stratégies

13.3 La leçon méthodologique

La littérature montre une chose : **les modèles les plus utiles ne sont pas les plus complexes**. Les nomogrammes additifs restent la référence clinique parce qu'ils sont transparents, validés et faciles à utiliser au lit du patient. Les modèles d'apprentissage profond, plus performants en laboratoire, échouent souvent au passage à l'échelle par manque de validation externe et de robustesse aux variations de protocole d'acquisition.

Pour un projet étudiant, la conséquence est claire : mieux vaut une régression bien conduite, avec une baseline, une validation croisée honnête et une discussion lucide des limites, qu'un modèle exotique non validé.

14. Votre jeu de données dans ce paysage

14.1 Origine

`prostate.csv` est le jeu de données de l'étude de **Stamey et al. (1989)**, portant sur 97 hommes traités par prostatectomie radicale à Stanford, et popularisé comme exemple de régression dans *An Introduction to Statistical Learning* [4,28]. Il contient 8 variables explicatives, une variable cible continue (`lpsa`) et un indicateur `train` (67 observations d'entraînement, 30 de test), sans valeur manquante.

L'apport historique de cette étude mérite d'être rappelé : Stamey et ses collègues ont établi qu'un centimètre cube de cancer élevait le PSA sérique d'environ 3,5 ng/mL, soit au moins dix fois plus que le tissu bénin [4]. C'est l'origine de l'idée que le PSA est un proxy du volume tumoral — idée qui fonde votre variable cible.

14.2 Les variables

Variable	Signification	Échelle	Moment de mesure
`lcavol`	log du volume tumoral (cm^3)	Continue	Pièce opératoire
`lweight`	log du poids de la prostate (g)	Continue	Pièce opératoire
`age`	Âge (années)	Continue	Pré-opératoire
`lbph`	log de la quantité d'hypertrophie bénigne	Continue	Pièce opératoire
`svi`	Envahissement des vésicules séminales (0/1)	Binaire	Pièce opératoire

Variable	Signification	Échelle	Moment de mesure
`lcp`	log de la pénétration capsulaire	Continue	Pièce opératoire
`gleason`	Score de Gleason total (6-9)	Ordinale	Pièce opératoire
`pgg45`	% de grades 4 ou 5	Continue (0-100)	Pièce opératoire
`lpsa`	log du PSA sérique	Continue (cible)	**Pré-opératoire**

14.3 Ce que cela permet, et ce que cela interdit

Ce jeu de données permet trois choses. Il permet d'illustrer une **chaîne de régression complète** : exploration, transformation, sélection de variables, pénalisation, validation. Il permet de montrer empiriquement que `lcavol` **porte l'essentiel du signal** (r = 0,73 avec `lpsa`, contre 0,57 pour `svi`, 0,55 pour `lcp`, 0,43 pour `lweight`, 0,42 pour `pgg45`, 0,37 pour `gleason`, 0,18 pour `lbph` et 0,17 pour `age`). Il permet enfin de discuter la **colinéarité** entre variables anatomopathologiques, qui justifie l'usage de Ridge ou du Lasso.

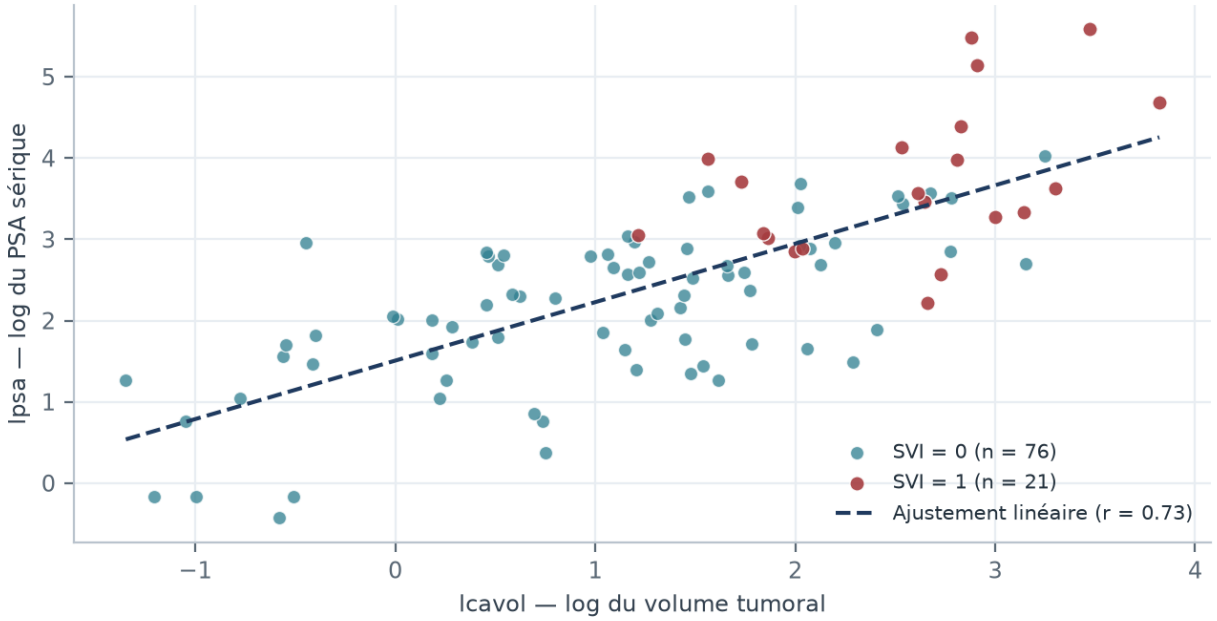


Figure 3 — Relation entre volume tumoral et PSA dans `prostate.csv`. Les patients avec envahissement des vésicules séminales (SVI = 1) se situent majoritairement au-dessus de la droite : à volume égal, leur PSA est plus élevé.

Il interdit en revanche une prétention clinique directe, pour trois raisons.

1. **La chronologie est inversée** : les variables explicatives sont majoritairement mesurées sur la pièce opératoire, donc *après* le dosage du PSA. Prédire le PSA à partir de ces variables n'a pas de sens comme outil de décision pré-opératoire.
2. **L'effectif est minuscule** : 97 patients, dont 30 en test. Un intervalle de confiance sur un R^2 calculé sur 30 observations est très large, et le risque de sur-ajustement est majeur.
3. **La cohorte est datée et située** : hommes américains, recrutés dans les années 1980, avant l'ère du PSA de dépistage et de l'IRM. Les distributions ne sont pas celles d'une population africaine contemporaine.

Ces limites ne disqualifient pas le projet : elles en définissent le périmètre. Le projet est une **démonstration méthodologique**, pas un dispositif médical. L'énoncé du TP demande un cycle complet jusqu'au déploiement — c'est la démarche qui est évaluée, pas la validité clinique.

> **À retenir** — Le jeu de données est un classique de la régression, avec une cible biologiquement fondée mais chronologiquement inversée. Il faut l'assumer explicitement dans le rapport : c'est ce qui distingue un travail rigoureux d'un travail naïf.

15. Ce qu'il faut retenir pour la suite du projet

1. **Le problème clinique central est la discrimination entre cancer indolent et cancer agressif**, pas la détection du cancer en soi. Toute formulation de problématique qui ignore cette nuance paraîtra naïve à un jury médical.
2. **Le PSA est un marqueur d'organe, pas de cancer** : sensibilité élevée, spécificité faible. C'est ce qui justifie l'usage de modèles multivariés.
3. **Le grade ISUP et le stade (dont `svi` et `lcp`) sont les déterminants majeurs du pronostic** après traitement local, avec le PSA.
4. **En Afrique subsaharienne, le retard diagnostique est le facteur dominant** : 45 % de stades IV, une survie à 5 ans de 60 %, un ratio mortalité/incidence de 54 %. C'est le cadre qui donne sa pertinence à un outil de priorisation.
5. **Votre jeu de données est un support pédagogique, pas une cohorte clinique** : 97 patients, variables post-opératoires, cohorte américaine des années 1980. À écrire noir sur blanc dans les limites.
6. **La rigueur méthodologique est le vrai livrable** : baseline, validation croisée, comparaison de modèles, intervalle de confiance, analyse de sensibilité, discussion des limites.

16. Limites de cette revue

Cette revue est narrative et sélective. Elle privilégie les sources en anglais, les publications indexées et les recommandations d'organismes de référence, au détriment de la littérature grise et des travaux africains publiés localement, souvent difficiles d'accès. Les chiffres épidémiologiques sont des **estimations** : GLOBOCAN modélise l'incidence à partir de registres partiels, et l'incertitude est particulièrement élevée en Afrique subsaharienne. Les recommandations citées (EAU, NCCN, USPSTF, ISUP) évoluent rapidement et doivent être vérifiées dans leur version la plus récente avant toute citation dans un rapport daté. Enfin, la section sur l'intelligence artificielle ne prétend pas à l'exhaustivité : elle vise à situer le projet, pas à réaliser un état de l'art complet.

17. Glossaire

Terme	Définition
ADT	*Androgen Deprivation Therapy* : hormonothérapie supprimant les androgènes
ASR	*Age-Standardized Rate* : taux standardisé sur l'âge, permettant de comparer des populations
csPCa	Cancer cliniquement significatif : ISUP ≥ 2, et/ou volume > 0,5 cm^3, et/ou extension extraprostatique
CRPC	Cancer de la prostate résistant à la castration
DRE	*Digital Rectal Examination* : toucher rectal

Terme	Définition
EPE	Extension extraprostatique (pT3a)
GG	*Grade Group* : groupe de grade ISUP, de 1 à 5
HBP	Hypertrophie bénigne de la prostate
ISUP	*International Society of Urological Pathology* : société à l'origine de la classification des grades
PIN	Néoplasie intraépithéliale prostatique, lésion précancéreuse
PI-RADS	Système de stratification du risque en IRM prostatique, de 1 à 5
PSA	*Prostate-Specific Antigen* : antigène prostatique spécifique, kallikréine-3
PSMA	*Prostate-Specific Membrane Antigen* : cible de l'imagerie et de la radiothérapie vectorisée
SVI	*Seminal Vesicle Invasion* : envahissement des vésicules séminales (pT3b)
TNM	Classification Tumor-Node-Metastasis

18. Références

1. Bray F, Laversanne M, Sung H, et al. Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA Cancer J Clin*. 2024. https://pubmed.ncbi.nlm.nih.gov/38572751
2. Ferlay J, Ervik M, Lam F, et al. Global Cancer Observatory: Cancer Today. Lyon : International Agency for Research on Cancer, 2024. Fiche « Prostate » : https://gco.iarc.who.int/media/globocan/factsheets/cancers/27-prostate-fact-sheet.pdf
3. McNeal JE. The zonal anatomy of the prostate. *Prostate*. 1981. https://pubmed.ncbi.nlm.nih.gov/7279811
4. Stamey TA, Kabalin JN, McNeal JE, et al. Prostate specific antigen in the diagnosis and treatment of adenocarcinoma of the prostate. II. Radical prostatectomy treated patients. *J Urol*. 1989;141(5):1076-1083. https://pubmed.ncbi.nlm.nih.gov/2468795
5. Epstein JI, Egevad L, Amin MB, et al. The 2014 International Society of Urological Pathology (ISUP) Consensus Conference on Gleason Grading of Prostatic Carcinoma. *Am J Surg Pathol*. 2016. https://pmc.ncbi.nlm.nih.gov/articles/PMC5002992
6. Cornford P, van den Bergh RCN, Briers E, et al. EAU-EANM-ESTRO-ESUR-ISUP-SIOG Guidelines on Prostate Cancer — 2023 Update. *Eur Urol*. 2024. https://pubmed.ncbi.nlm.nih.gov/38614820
7. D'Amico AV, Whittington R, Malkowicz SB, et al. Biochemical outcome after radical prostatectomy, external beam radiation therapy, or interstitial radiation therapy for clinically localized prostate cancer. *JAMA*. 1998;280(11):969-974. Synthèse accessible : https://www.mdcalc.com/calc/2049/damico-risk-classification-prostate-cancer
8. US Preventive Services Task Force. Prostate Cancer: Screening. Recommendation statement, 2018. https://www.uspreventiveservicestaskforce.org/uspstf/recommendation/prostate-cancer-screening
9. Schröder FH, Hugosson J, Roobol MJ, et al. Screening and prostate-cancer mortality in a randomized European study (ERSPC). *N Engl J Med*. 2009;360:1320-1328.
10. Andriole GL, Crawford ED, Grubb RL, et al. Mortality results from a randomized prostate-cancer screening trial (PLCO). *N Engl J Med*. 2009;360:1310-1319. https://www.nejm.org/doi/full/10.1056/NEJMoa0810696
11. Jin Y, et al. Diagnostic accuracy of prostate-specific antigen below 4 ng/mL: a systematic review and meta-analysis. *Investig Clin Urol*. 2022. https://icurology.org/DOIx.php?id=10.4111/icu.20210429

12. David MK, Leslie SW. Prostate-Specific Antigen. *StatPearls*. 2024. https://www.ncbi.nlm.nih.gov/books/NBK557495

13. National Cancer Institute. Prostate-Specific Antigen (PSA) Test. 2025. https://www.cancer.gov/types/prostate/psa-fact-sheet

14. Turkbey B, Rosenkrantz AB, Haider MA, et al. PI-RADS v2.1. *Eur Urol*. 2019. Synthèse : https://radiologyassistant.nl/abdomen/prostate/prostate-cancer-pi-rads-v2-1

15. Kattan MW, Wheeler TM, Scardino PT. Postoperative nomogram for disease recurrence after radical prostatectomy for prostate cancer. *J Clin Oncol*. 1999;17:1499-1507. Mise à jour : https://acsjournals.onlinelibrary.wiley.com/doi/10.1002/cncr.23293 — validation externe : https://pmc.ncbi.nlm.nih.gov/articles/PMC6373767

16. Hamdy FC, Donovan JL, Lane JA, et al. 10-Year Outcomes after Monitoring, Surgery, or Radiotherapy for Localized Prostate Cancer (ProtecT). *N Engl J Med*. 2016;375:1415-1424. https://www.nejm.org/doi/full/10.1056/NEJMoa1606220

17. Hamdy FC, Donovan JL, Lane JA, et al. Fifteen-Year Outcomes after Monitoring, Surgery, or Radiotherapy for Localized Prostate Cancer. *N Engl J Med*. 2023. https://www.nejm.org/doi/full/10.1056/NEJMoa2214122

18. Sartor O, de Bono J, Chi KN, et al. Lutetium-177-PSMA-617 for Metastatic Castration-Resistant Prostate Cancer (VISION). *N Engl J Med*. 2021;385:1091-1103. https://pubmed.ncbi.nlm.nih.gov/34161051

19. Seraphin TP, et al. Prostate cancer survival in sub-Saharan Africa by age, stage at diagnosis, and human development index: a registry-based study. *Cancer Causes Control*. 2021. https://pmc.ncbi.nlm.nih.gov/articles/PMC8310516

20. Organisation mondiale de la santé, Bureau régional Afrique. Understanding Africa's prostate cancer prevalence, risks and prevention mechanisms. 2025. https://www.afro.who.int/countries/senegal/news/understanding-africas-prostate-cancer-prevalence-risks-and-prevention-mechanisms

21. Carroll PR, Parsons JK, Andriole G, et al. NCCN Guidelines Insights: Prostate Cancer Early Detection. *J Natl Compr Canc Netw*. 2016. https://pmc.ncbi.nlm.nih.gov/articles/PMC10184498 — communiqué NCCN 2023 : https://www.nccn.org/home/news/newsdetails?NewsId=3643

22. Haiman CA, Chen GK, Blot WJ, et al. Characterizing genetic risk at known prostate cancer susceptibility loci in African Americans. *PLoS Genet*. 2011. https://journals.plos.org/plosgenetics/article?id=10.1371/journal.pgen.1001387

23. Johnson JR, Woods-Burnham L, Hooker SE, et al. Genetic Contributions to Prostate Cancer Disparities in Men of African Descent. *Front Oncol*. 2021. https://www.frontiersin.org/journals/oncology/articles/10.3389/fonc.2021.770500/full

24. Ling C, et al. Diagnostic systematic review and meta-analysis of machine learning techniques for prostate cancer prediction. *Sci Rep*. 2025. https://www.nature.com/articles/s41598-025-11445-5

25. Molière S, et al. A Systematic Review of the Diagnostic Accuracy of Deep Learning for Prostate Cancer Detection on MRI. *Eur Urol Open Sci*. 2024. https://www.sciencedirect.com/science/article/pii/S2588931124002487

26. National Cancer Institute. SEER Cancer Stat Facts: Prostate Cancer. https://seer.cancer.gov/statfacts/html/prost.html

27. American Cancer Society. Survival Rates for Prostate Cancer. https://www.cancer.org/cancer/types/prostate-cancer/detection-diagnosis-staging/survival-rates.html

28. James G, Witten D, Hastie T, Tibshirani R. *An Introduction to Statistical Learning*. Springer, 2e édition. Chapitre 6 (Linear Model Selection and Regularization).